

VLM의 한국어 장면 텍스트 이해를 위한 학습 데이터 구성과 CoT 추론 효과 분석

한주현¹, 방민재², 배유석³, 윤기민^{3,4,*}

¹한국항공대학교, ²Columbia University,

³한국전자통신연구원 시각지능연구실, ⁴과학기술연합대학원대학교

e-mail : hjh5842@kau.kr, mb4882@columbia.edu, {baeys, kimin.yun}@etri.re.kr

* corresponding author

Data Composition Strategies and CoT Inference for VLM-based Korean Scene Text Recognition

*Juhyeon Han, Minjae Bang, Yuseok Bae, Kimin Yun

¹Korea Aerospace University, ²Columbia University,

³Visual Intelligence Lab., ETRI, ⁴University of Science and Technology

Abstract

This study investigates the performance of Vision-Language Models (VLMs) for Korean scene text recognition and qualitatively examines the impact of dataset composition and training strategies. We fine-tuned the Qwen2.5-VL-3B model in a vision-only setting, comparing different ratios of Crop, Flat, and Warp data, the use of Chain-of-Thought (CoT) prompt designs. Our case-based analysis indicates that balanced datasets yield the most stable recognition and classification, while CoT improves interpretability and consistency. These findings highlight both the potential and limitations of VLMs in complex Korean scene text environments and suggest directions for future multimodal OCR research.

I. 서론

장면 텍스트 인식(Scene Text Recognition, STR)은 공공 안내, 교통 표지판, 상업 광고, 선거 홍보 등 다양한 영역에서 활용된다. 그러나 현수막과 같은 비정형 장면은 복잡한 배경, 다양한 글꼴과 색상, 조명 변화,

기울기·왜곡 등으로 인해 글자 인식의 성능이 크게 저하된다. 특히 한국어는 자모 결합 구조와 불규칙한 띄어쓰기 등 언어적 특성으로 인해 영어보다 인식 난도가 높다.

최근 Vision-Language Model(VLM)은 이미지와 텍스트를 함께 학습하여 단순 인식을 넘어 의미 해석과 추론까지 수행할 수 있는 새로운 접근으로 주목받고 있다. LLaVA[1], Qwen-VL[2] 등은 문서 분석과 표·차트 해석에서 성과를 보였으나, 영어 중심 학습에 치중되어 한국어 장면 텍스트 처리에는 한계가 있다.

이러한 문제를 해결하기 위해 본 연구에서는 한국어 현수막 데이터를 대상으로 Qwen2.5-VL-3B[2] 모델을 Vision-only 방식으로 파인튜닝하고, 데이터셋 구성에 따른 한국어 이해 성능을 향상을 위한 전략을 연구하고, 또한 downstream task로서 내용 기반의 현수막의 종류 분류 성능에 미치는 영향을 비교·분석한다. 이를 통해 한국어 STR에서 VLM 활용의 가능성과 한계를 탐색하고, 향후 멀티모달 기반 Text 내용 인식에 관한 연구 방향을 제시한다.

II. 관련 연구

2.1 OCR 기반 장면 텍스트 인식

전통적인 장면 텍스트 인식 연구는 OCR 기법에 기

반하였으며, CRNN[3]과 같은 CNN - RNN 구조 및 Transformer 기반 모델이 문자 인식 성능을 크게 향상시켰다. 그러나 Tesseract[4], PaddleOCR[5] 등 기존 툴킷은 문서 환경에서는 우수하나, 배경이 복잡하고 왜곡이 심한 현수막과 같은 장면 텍스트에서는 성능 저하가 뚜렷하다.

2.2 Vision-Language Model(VLM)

최근 VLM은 이미지와 텍스트를 동시에 학습하여 단순한 문자 인식을 넘어 의미 해석과 추론까지 가능하게 하며, LLaVA, Qwen-VL 등은 다양한 응용에서 성과를 보였다. GOT-OCR[6]은 VLM에서 OCR만을 위한 데이터로 학습하였으나, 대부분 영어와 중국어 중심 학습 데이터에 편중되어 한국어 장면 텍스트에는 한계가 있다.

III. 본론

한국어 장면 텍스트 인식은 자모 결합 구조, 불규칙한 띄어쓰기 등 언어적 특성으로 인해 난이도가 높음에도 연구가 상대적으로 부족하다. 공개 데이터셋도 제한적이어서 성능 편향 문제가 존재한다. 따라서 한국어 현수막과 같은 실제 장면을 대상으로 VLM의 성능을 검증하고, 데이터 구성 및 학습 전략의 영향을 체계적으로 분석하는 연구가 요구된다.

3.1 전체 파이프라인 개요

현수막 이미지는 건물·차량 등 불필요한 배경 요소가 포함되어 인식 정확도를 저하시킬 수 있다. 이를 해결하기 위해 Detection으로 현수막 영역을 추출하고, Segmentation과 Warping을 통해 기울기 및 왜곡을 보정하였다. 최종 전처리된 이미지는 VLM에 입력되어 문자 인식 및 종류 분류 실험에 활용되었다.

3.2 Vision-Language Model 선정 및 파인튜닝

Baseline 모델로는 Qwen2.5-VL을 활용하였다. 기본적으로 학습데이터에 한국어를 많이 포함한 모델로서, Qwen2.5-VL-3B는 정형 문서와 비정형 현수막 환경 모두에서 안정적 성능을 보였으며, 3B 규모로 파인튜닝 효율성이 높아 최종 대상으로 선정되었다. 파인튜닝은 Vision-only 방식으로 Vision Tower만 미세조정하여 시각 표현 학습에 집중하였다.

3.3 데이터셋 구성

데이터셋은 세 가지 형태로 변환하였다. 원본에서 현수막 영역만 추출한 Crop, Crop된 이미지를 평면화



그림 1. 데이터셋 예시: (a) Crop - 텍스트 영역 추출, (b) Warp - 투영 변환 적용, (c) Flat - 디지털 현수막 원본

적용해 왜곡을 보정한 Warp, 그리고 전처리 없이 디지털 제작물 형태를 유지한 Flat이다. 그림 1은 세 가지 데이터 형태의 예시를 보여준다.

3.4 CoT 추론 프롬프트 설계

LLM에서 Chain-of-thought 기법을 추론에 활용해도 성능이 높아진다는 것이 알려져있듯, 본 연구에서도 현수막의 텍스트 인식 후 분류를 수행하는 Simple 프롬프트 텍스트 인식 후 정당·공공·민간으로 분류하며 근거까지 제시하게 하는 CoT 추론 프롬프트를 사용하였고 이를 통해 인식 정확도와 해석 가능성을 함께 평가하였다. 상세한 프롬프트는 아래 표1과 같다.

표 1. Simple 프롬프트와 CoT 추론 프롬프트 구성

"simple": (" 이 현수막에 적힌 글자를 읽어주세요.WnWn" "출력 형식:Wn" "- 현수막 내용: [읽은 텍스트]Wn" "- 분류: [정당/인간/공공 현수막]Wn" "- 판단 이유: [분류 근거]"
"CoT추론": ("<obj>이 현수막</obj>" "위 현수막의 텍스트를 꼼꼼하게 읽고, 내용을 말해주 세요. "그 후 이 현수막이 '정당 현수막', '민간 현수막', '공공 현수막' 중 어디에 해당하는지도 함께 판단해주세요.WnWn" "판단 기준:Wn" "1. 정당 현수막: 정당명, 후보자, 선거 관련 문구 포함 Wn" "2. 민간 현수막: 상업 광고, 학원/상점/개인 목적 문구 포함Wn" "3. 공공 현수막: 정부, 지자체, 공공기관 명칭 또는 정

책, 단속, 행정 안내 등 공익적 내용 포함WnWn"
 "출력 형식:Wn"
 "- 현수막 내용 : 현수막 내용 읽기Wn"
 "- 분류 결과: 정당 현수막 / 민간 현수막 / 공공 현수막Wn"
 "- 판단 이유: 텍스트나 문맥을 근거로 분류 이유 설명")

IV. 실험 및 결과 분석

4.1 데이터셋 및 실험 설계

VLM이 입력으로 받아들이는 형태의 이미지에 대해서 현수막 데이터를 형태별 데이터를 섞어서 학습에 활용하였다. 이러한 데이터셋 구성의 효과를 확인하기 위해서, Crop, Warp, Crop의 데이터 비율을 변형하여 BAL-Equal은 1:1:1, C3F2W1은 3:2:1, CW-Only는 1:1:0, No-Warp는 1:0:1로서 구성하여 성능을 측정하였다. 총 학습 데이터는 8,400장, validation 데이터로는 1,047장의 이미지 데이터를 사용하였다. 평가 지표로는 VLM이 출력하는 문장의 전체적인 의미 유사도 측정을 위해 ROUGE-L[7]을 사용하였다.

4.2 파인튜닝 및 학습 설정

Qwen2.5-VL-3B-Instruct를 Vision-only 방식으로 파인튜닝하였다. Vision Tower만 미세조정하고 언어 모듈과 프로젝터는 고정하여 한국어 현수막 특화 시각 표현 학습에 집중하였다. 입력 크기는 451,584 pixels로 고정하였고, bf16 혼합 정밀도와 linear warmup 스케줄러를 적용하였다. Vision Tower와 Projector에는 서로 다른 학습률을 부여하였다.

4.3 Chain-of-Thought(CoT) 추론 효과

그림 2 및 표 2와 같이 CoT 추론을 적용함에 따라 Qwen 베이스라인 대비 한국어 장면 텍스트 이해 성능이 향상된 것을 알 수 있다. CoT 추론은 학습 데이터에 CoT가 포함되지 않은 모델에서도 추론 시점에 단계별 사고 과정을 유도함으로써 현수막이 가질 수 있는 단어의 이해 성능을 향상시킬 수 있는 것도 확인하였다. 실험 결과, 학습 후 CoT 추론을 적용하지 않은 기본 모델들의 평균 성능은 0.58이었으나, 동일한 모델에 CoT 추론만 적용했을 때 평균 0.60으로 3.5%의 성능 향상을 보였다.

Qwen(baseline): 900만원대 아파트 초역세권 092.870.9788
Proposed: 도원역 900만원대 아파트 초역세권 032.870.9788
Qwen(baseline): 금산군청 사이클링팀 단체장
Proposed: 8.15 경축 2024 임양국제사이클대회 오픈부문 금산군청 사이클팀 장경구 1위 우승

그림 2. 한국어 장면 텍스트 인식 결과 비교

표 2. 데이터셋 조합과 CoT 추론 조합에 따른 장면 텍스트 인식 정확도

데이터 조합	CoT 추론	ROUGE-L
Qwen (baseline)	X	0.4257
Qwen (baseline)	O	0.4875
BAL-Equal	X	0.5706
BAL-Equal	O	0.6072
C3F2W1	X	0.5865
C3F2W1	O	0.6039
CW-Only	X	0.5785
CW-Only	O	0.5983
No-Warp	X	0.5845
No-Warp	O	0.5925

또한, 정성적으로도 글자 인식만을 명령하는 Simple 프롬프트는 행사명·일시·장소 등 핵심 문구가 부분적으로 누락되거나 부정확하게 인식되는 경우가 있었다. 반면 OCR+근거+분류를 진행하는 CoT 추론 프롬프트는 텍스트 인식과 동시에 유형 분류 및 근거 설명까지 수행하도록 지시하여, 인식 결과가 더 구조화되고 문맥이 정리된 출력을 생성하였다. 예컨대 웹사이트 주소 철자를 보정하거나 행사 안내 문구를 문맥에 맞게 재구성하는 등 출력 품질과 분류 일관성이 향상되는 경향을 보였다.

4.5 데이터 비율에 따른 성능 분석

학습 데이터의 시각적 특성이 모델 성능에 미치는 영향을 분석한 결과, 평면 현수막 데이터 (Flat, Warp)의 포함 여부가 성능에 영향을 미치는 것으로 나타났다. 기하학적 변형을 적용하지 않은 원본 현수막만을 사용한 데이터셋 (No-Warp)에서는 상대적으로 낮은 성능을 보였다. 이는 VLM이 일반적으로 평면 문서에서 높은 텍스트 인식 성능을 보이는 기본적인 역량과 일치하는 결과이다. 즉, 곡면이나 기울어진 형태의 현수막을 평면으로 변환한 데이터를 학습에 포함 시킴으로써 모델이 보다 명확하고 인식하기 쉬운 텍스트 형태에서 출발하여 효과적인 학습이 가능했던 것으로 생각된다.

IV. 결론 및 향후 연구 방향

본 연구는 Vision-Language Model을 활용한 한국어 현수막의 장면 텍스트 인식 및 분류에서 데이터셋의 구성에 따른 성과 Chain-of-Thought(CoT) 추론 기법의 효과를 분석하였다. CoT 추론은 모든 실험 설정에서 성능 향상을 보이는 결과를 얻었다. 또한 평면화된 현수막 데이터를 포함한 학습이 VLM의 기본적인 문서 인식 능력을 효과적으로 활용하여 더 나은 성능이 얻어짐을 확인하였다. 향후 연구에서는 보다 인식된 텍스트 내용을 정량적으로 평가하고 텍스트 인식과 분류 성능 간의 상관관계를 분석하고, 대규모 데이터셋을 통한 일반화 검증 및 CoT 기법의 효과 메커니즘에 대한 심층 분석을 진행할 예정이다.

Acknowledgements

본 연구는 2025년도 과학기술정보통신부 및 정보통신기획평가원의 사람중심인공지능핵심원천기술개발사업(RS-2022-II220124, 스스로 학습 역량을 인지하고 활용하여 적정한 결과를 제공하는 인공지능 기술 개발)과 2024년도 산업통상자원부 산업혁신인재성장지원사업(항공방산SW 전문인력양성)(RS-2024-00412499) 및 하계 UST 연구인턴십의 연구로 수행된 결과임

참고문헌

- [1] H. Liu, C. Li, Q. Wu., Y. Lee, and R. Girdhar, "Visual Instruction Tuning," in *Advances in Neural Information Processing Systems*, 2023.
- [2] S. Bai, K. Chen, X. Liu, J. Wang, W. Ge, S.

Song, K. Dang, P. Wang, S. Wang, J. Tang, H. Zhong, Y. Zhu, M. Yang, Z. Li, J. Wan, P. Wang, W. Ding, Z. Fu, Y. Xu, J. Ye, X. Zhang, T. Xie, Z. Cheng, H. Zhang, Z. Yang, H. Xu, and J. Lin, "Qwen2.5-VL Technical Report", arXiv, 2025.

- [3] B. Shi, X. Bai, and C. Yao, "An End-to-End Trainable Neural Network for Image-based Sequence Recognition and Its Application to Scene Text Recognition", *IEEE Transactions on Pattern Analysis and Machine Intelligence*, Vol. 39, 2017.
- [4] Tesseract Open Source OCR Engine, <https://github.com/tesseract-ocr/tesseract>
- [5] C. Cui, T. Sun, M. Lin, T. Gao, Y. Zhang, J. Liu, X. Wang, Z. Zhang, C. Zhou, H. Liu, Y. Zhang, W. Lv, K. Huang, Y. Zhang, J. Zhang, J. Zhang, Y. Liu, D. Yu, and Y. Ma, PaddleOCR 3.0 Technical Report, arXiv, 2025.
- [6] H. Wei, C. Liu, J. Chen, J. Wang, L. Kong, Y. Xu, Z. Ge, L. Zhao, J. Sun, Y. Peng, C. Han, and X. Zhang, "General OCR Theory: Towards OCR-2.0 via a Unified End-to-end Model", arXiv, 2024
- [7] C. Lin, "ROUGE: A Package for Automatic Evaluation of Summaries", *Text summarization branches out*, 2004.